Riesgo de Crédito y Tasas de Impago: Modelado de Probabilidad de Incumplimiento (PD) con Machine Learning, Calibración y Explicabilidad

1. Marco teórico

1.1. Objetivo del modelado de riesgo de crédito

El riesgo de crédito estudia la posibilidad de que una persona, empresa o contraparte *no cumpla* con sus obligaciones de pago en un horizonte de tiempo determinado. En un contexto de originación de crédito (solicitud y aprobación), una tarea central es estimar la **probabilidad de impago** (**PD**, por sus siglas en inglés: *Probability of Default*) de cada solicitante o préstamo, a partir de información observada (perfil del cliente, características del crédito, historial de pagos, entre otras).

Desde el punto de vista de ciencia de datos, el problema puede formularse como:

- un problema de **clasificación binaria** (impago / no impago), y
- un problema de **predicción probabilística** (asignar probabilidades bien calibradas).

En aplicaciones reales, no basta con que un modelo "ordene" bien a los clientes de mayor a menor riesgo; también se requiere que las probabilidades estimadas sean **coherentes** con las frecuencias observadas (calibración), y que el sistema sea **explicable** para auditoría, supervisión, validación y toma de decisiones.

1.2. Variable objetivo, horizonte y formulación probabilística

1.2.1. Definición de la variable objetivo

Sea $Y \in \{0, 1\}$ la variable objetivo, donde:

$$Y = \begin{cases} 1, & \text{si el préstamo incurre en impago dentro del horizonte definido,} \\ 0, & \text{si no incurre en impago dentro del horizonte definido.} \end{cases}$$

El **horizonte temporal** debe definirse explícitamente. Ejemplos comunes:

- 3 meses,

- 6 meses,
- 12 meses (muy usado en PD),
- vida del préstamo (según dataset y objetivos).

Nota importante (diseño del target). La definición de "impago" depende del dataset y del contexto: puede corresponder a `default`, `charge-off`, mora severa (por ejemplo, 90+ días de atraso), o un evento equivalente. Esta definición influye fuertemente en:

- la prevalencia de la clase positiva,
- la dificultad del problema,
- la interpretación de la PD.

1.2.2. Vector de características

Sea $X = (X_1, \ldots, X_p) \in \mathbb{R}^p$ (o mixto numérico-categórico tras codificación) el vector de variables explicativas del solicitante/préstamo, por ejemplo:

- ingreso, antigüedad laboral, razón deuda/ingreso,
- monto solicitado, plazo, tasa de interés,
- historial de atraso, número de créditos previos,
- variables derivadas (ratios, conteos, agregaciones).

1.2.3. Definición de probabilidad de impago (PD)

La probabilidad de impago condicional se define como:

$$\mathrm{PD}(x) = \mathbb{P}(Y = 1 \mid X = x).$$

El objetivo de modelado es construir un estimador

$$\widehat{\mathrm{PD}}(x) \approx \mathbb{P}(Y = 1 \mid X = x),$$

que sea útil para:

1. ranking de riesgo,
2. decisión (aceptar/rechazar, precio, límites),
3. monitoreo,
4. análisis de portafolio y segmentación.

1.3. Tasa de impago por segmentos (análisis descriptivo y de validación)

Además de modelar a nivel individual, es fundamental estudiar **tasas de impago por segmentos**. Sea S un subconjunto (segmento) del conjunto de observaciones, por ejemplo:

- plazo = 36 meses,
- nivel de ingreso bajo/medio/alto,
- grado de crédito,
- cohorte de originación (mes o trimestre),
- región geográfica.

La tasa de impago observada del segmento S se estima como:

$$\widehat{r}(S) = \frac{\#\{i \in S : Y_i = 1\}}{\#\{i \in S\}}.$$

1.3.1. Interpretación

Las tasas segmentadas sirven para:

- **EDA** (análisis exploratorio): detectar segmentos de mayor riesgo;
- **monitoreo**: observar cambios temporales o de mezcla de cartera;
- **validación cualitativa**: comprobar si el modelo asigna mayor riesgo donde la tasa observada históricamente es mayor.

1.3.2. Ejemplo básico

Supongamos 3 segmentos por plazo:

$$S_{12} = \text{plazo 12m}, \quad S_{24} = \text{plazo 24m}, \quad S_{36} = \text{plazo 36m}.$$

Si se observa:

$$\widehat{r}(S_{12}) = 0{,}03, \qquad \widehat{r}(S_{24}) = 0{,}06, \qquad \widehat{r}(S_{36}) = 0{,}10,$$

entonces una regularidad esperable es que, *en promedio*, las PD estimadas por el modelo también crezcan con el plazo (si todo lo demás permanece comparable).

1.4. Clasificación binaria y predicción probabilística

1.4.1. Dos salidas del modelo: score y etiqueta

Un modelo de riesgo produce típicamente una de estas salidas:

1. **Score o probabilidad estimada** $\hat{p}_i \in [0, 1]$;
2. **Etiqueta predicha** $\hat{y}_i \in \{0, 1\}$, obtenida mediante un umbral τ:

$$\hat{y}_i = \mathbf{1}\{\hat{p}_i \geq \tau\}.$$

Idea clave. En riesgo de crédito, la salida probabilística $\hat{p}_i$ es especialmente importante porque:

- permite calibración,
- facilita segmentación y monitoreo,
- soporta decisiones con umbrales variables y costos de negocio.

1.4.2. Matriz de confusión y errores

Dados Y y $\hat{Y}$, se distinguen:

- **TP** (verdaderos positivos): impagos correctamente detectados,
- **FP** (falsos positivos): clientes buenos clasificados como impago,
- **TN** (verdaderos negativos): no-impagos correctamente clasificados,
- **FN** (falsos negativos): impagos no detectados.

En riesgo de crédito, los FN suelen ser costosos (otorgar crédito a quien impagará), pero los FP también importan (rechazar buenos clientes).

1.5. Modelo baseline: regresión logística

1.5.1. Motivación

La regresión logística es el **baseline clásico** en riesgo de crédito por su:

- interpretabilidad,
- estabilidad,
- facilidad de implementación,
- utilidad para auditoría y validación.

1.5.2. Modelo

La regresión logística modela la probabilidad mediante:

$$\operatorname{logit}(p(x)) = \log\left(\frac{p(x)}{1-p(x)}\right) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p = \beta_0 + \beta^\top x.$$

Equivalente a:

$$p(x) = \frac{1}{1+\exp[-(\beta_0 + \beta^\top x)]}.$$

Cuando el modelo está ajustado, se usa:

$$\hat{p}(x) = \frac{1}{1+\exp[-(\hat{\beta}_0 + \hat{\beta}^\top x)]}.$$

1.5.3. Interpretación de coeficientes

Cada coeficiente β_j representa el cambio en el *log-odds* por unidad de x_j, manteniendo constantes las demás variables:

$$\beta_j = \frac{\partial}{\partial x_j} \log\left(\frac{p}{1-p}\right).$$

La cantidad $\exp(\beta_j)$ se interpreta como **odds ratio** multiplicativo por incremento unitario en x_j.

Ejemplo básico (interpretación). Si $\beta_j = 0{,}4$, entonces:

$$\exp(0{,}4) \approx 1{,}49.$$

Esto significa que, al aumentar x_j una unidad (todo lo demás fijo), las *odds* de impago se multiplican por 1,49 (aumento aproximado de 49 % en odds, no en probabilidad directa).

Si $\beta_j = -0{,}7$, entonces:

$$\exp(-0{,}7) \approx 0{,}50,$$

es decir, las odds se reducen aproximadamente a la mitad.

1.5.4. Función de pérdida (entrenamiento)

La logística suele ajustarse por máxima verosimilitud, equivalente a minimizar la **log-loss** binaria (entropía cruzada):

$$\mathcal{L}(\beta) = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log(\hat{p}_i) + (1-y_i)\log(1-\hat{p}_i)\right].$$

Esta pérdida penaliza fuertemente predicciones muy confiadas pero erróneas.

1.5.5. Regularización

Para mejorar generalización y estabilidad:

- **L2 (Ridge):** penaliza $\sum_j \beta_j^2$,
- **L1 (Lasso):** penaliza $\sum_j |\beta_j|$ (puede inducir sparsidad),
- **Elastic Net:** combinación L1 + L2.

Por qué es importante en este proyecto. En datasets con muchas variables (incluyendo *one-hot encoding*), la regularización ayuda a:

- reducir sobreajuste,
- estabilizar coeficientes,
- mejorar reproducibilidad.

1.5.6. Supuestos y limitaciones (prácticas)

La regresión logística no requiere normalidad de X, pero su desempeño e interpretación mejoran si:

- la relación entre algunas variables y el log-odds es aproximadamente lineal,
- no hay multicolinealidad extrema,
- hay codificación adecuada de variables categóricas,
- se controlan outliers e inconsistencias.

Limitación principal. Puede no capturar bien interacciones complejas y no linealidades, lo que motiva el uso de modelos ML.

1.6. Modelos de machine learning basados en árboles

1.6.1. Motivación

Muchos fenómenos de impago dependen de relaciones no lineales e interacciones entre variables (por ejemplo, el efecto del ingreso puede depender del plazo o del historial). Modelos basados en árboles pueden capturar estas estructuras de forma flexible.

1.6.2. Árboles de decisión (idea básica)

Un árbol divide el espacio de variables por reglas del tipo:

$$x_j \leq c \quad \text{o} \quad x_j > c,$$

generando nodos y hojas. En clasificación, una hoja puede asignar una probabilidad

$$\hat{p} = \frac{\#\text{positivos en la hoja}}{\#\text{observaciones en la hoja}}.$$

Ejemplo intuitivo. Un árbol podría aprender reglas como:

- si `historial_mora` >2, riesgo alto;
- si `historial_mora` ≤ 2 y `ingreso` alto, riesgo bajo;
- si `historial_mora` ≤ 2 pero `plazo`=60m, riesgo medio-alto.

1.6.3. Random Forest (RF)

Un **Random Forest** ensambla muchos árboles:

- cada árbol se entrena con una muestra *bootstrap* del train,
- en cada partición se consideran subconjuntos aleatorios de variables.

La predicción final es el promedio (en probabilidades) o votación (en clases).

Ventajas.

- buena capacidad predictiva,
- robustez frente a ruido y no linealidades,
- menor sobreajuste que un solo árbol (en general).

Limitaciones.

- menor interpretabilidad que logística,
- probabilidades a veces mal calibradas,
- mayor costo computacional.

1.6.4. Gradient Boosting (GBM, XGBoost/LightGBM/CatBoost como familia)

El **Gradient Boosting** construye árboles de forma secuencial, donde cada nuevo árbol corrige errores del ensamble previo (equivalentemente, sigue el gradiente de una función de pérdida).

Idea simplificada. Si $f_m(x)$ es el modelo en la iteración m, se actualiza:

$$f_{m+1}(x) = f_m(x) + \eta\, h_m(x),$$

donde h_m es un árbol pequeño y η es la tasa de aprendizaje.

Ventajas.

- alto desempeño predictivo en datos tabulares,
- captura interacciones y no linealidades de forma potente.

Riesgo.

- puede sobreajustar si no se regula (profundidad, learning rate, número de árboles),
- frecuentemente requiere calibración posterior si se usan probabilidades.

1.6.5. Importancia de comparar con baseline

Aunque modelos de árboles puedan mejorar AUC/PR-AUC, la logística sigue siendo referencia por:

- interpretabilidad,
- facilidad de auditoría,
- desempeño competitivo en varios contextos.

Por ello es buena práctica comparar:

$$\text{Logística (baseline)} \quad \text{vs} \quad \text{RF / GBM.}$$

1.7. Desbalance de clases en riesgo de impago

1.7.1. Qué es el desbalance

En muchos datasets de crédito, el impago es relativamente raro:

$$\pi = \mathbb{P}(Y = 1) \ll 0{,}5.$$

Por ejemplo, puede haber una prevalencia de 5 % a 15 %, o incluso menor.

Problema. Un clasificador trivial que predice siempre 0 puede alcanzar alta exactitud (*accuracy*), pero ser inútil para detectar impagos.

1.7.2. Consecuencias del desbalance

- **Accuracy** puede ser engañosa.
- Modelos pueden favorecer la clase mayoritaria.
- Umbral por defecto $\tau = 0{,}5$ suele ser inadecuado.
- Debe prestarse más atención a **recall**, **PR-AUC**, y calibración.

1.7.3. Estrategias para tratar el desbalance

1) Ponderación de clases (*class weights*) Se asigna mayor peso a errores en la clase minoritaria en la función de pérdida. En forma simplificada:

$$\mathcal{L}_{\text{weighted}} = -\frac{1}{n}\sum_{i=1}^{n} w_{y_i}\Big[y_i \log(\hat{p}_i) + (1 - y_i)\log(1 - \hat{p}_i)\Big].$$

Con $w_1 > w_0$, el modelo atiende más la clase de impago.

2) Submuestreo de la clase mayoritaria Se reduce el número de ejemplos negativos para balancear el train. Ventaja: entrenamiento más rápido. Desventaja: pérdida de información.

3) Sobremuestreo de la clase minoritaria Se duplican o generan más ejemplos positivos. Puede ayudar al aprendizaje, pero si se hace de forma ingenua puede favorecer sobreajuste.

4) SMOTE (*Synthetic Minority Over-sampling Technique*) SMOTE genera ejemplos sintéticos interpolando entre vecinos de la clase minoritaria. A nivel conceptual:

$$x_{\text{nuevo}} = x_i + \lambda(x_{nn} - x_i), \quad \lambda \in (0, 1).$$

Precaución metodológica (muy importante). SMOTE (y cualquier remuestreo) debe aplicarse **sólo al conjunto de entrenamiento** dentro del pipeline / validación cruzada, **nunca** antes de separar train/test, para evitar fuga de información (*data leakage*).

1.7.4. Ejemplo conceptual

Supongamos un train con:

$$n_0 = 9000, \qquad n_1 = 1000 \quad (10\,\%\text{ impago}).$$

Un modelo sin tratamiento de desbalance podría priorizar la clase 0. Con *class weights* proporcionales al inverso de frecuencia:

$$w_1 \approx \frac{9000 + 1000}{2 \cdot 1000} = 5, \qquad w_0 \approx \frac{10000}{2 \cdot 9000} \approx 0{,}56.$$

Entonces los errores sobre impago reciben una penalización mucho mayor.

1.8. Partición de datos, validación y prevención de fuga de información

1.8.1. Partición train/validation/test

Una práctica estándar es dividir el conjunto de datos en:

- **Train**: entrenamiento del modelo,
- **Validation**: selección de hiperparámetros, calibración post-hoc,
- **Test**: evaluación final (una sola vez idealmente).

Recomendación. Usar partición estratificada para preservar la prevalencia de impago en cada subconjunto.

1.8.2. Validación cruzada

Cuando el dataset lo permite, puede emplearse validación cruzada (CV) estratificada. Esto reduce varianza en la estimación de desempeño y ayuda a comparar modelos.

1.8.3. Data leakage (fuga de información)

Existe fuga si una variable contiene información no disponible al momento de la decisión (o si la preparación de datos usa información del test). Ejemplos:

- usar variables posteriores al otorgamiento del crédito para PD de originación,
- calcular escalamiento/imputación en todo el dataset antes de separar test,
- aplicar SMOTE antes de la partición.

Principio rector. El pipeline debe simular el escenario real de predicción.

1.9. Métricas de evaluación: discriminación vs calibración

Una idea central del proyecto es distinguir dos dimensiones:

1. **Discriminación**: qué tan bien ordena el modelo (separa impagos de no impagos),
2. **Calibración**: qué tan bien las probabilidades estimadas coinciden con frecuencias observadas.

1.9.1. Métricas de clasificación a umbral

Dado un umbral τ, se define:

$$\hat{y}_i = \mathbf{1}\{\hat{p}_i \geq \tau\}.$$

Métricas principales:

$$\begin{aligned} \text{Precisión (PPV)} &= \frac{TP}{TP + FP}, \\ \text{Recall (TPR, sensibilidad)} &= \frac{TP}{TP + FN}, \\ \text{F1} &= 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}}. \end{aligned}$$

Interpretación en crédito.

- Mayor **recall**: detecta más impagos (menos FN),
- Mayor **precisión**: menos buenos clientes mal marcados (menos FP).

La elección del umbral depende del costo relativo de FN y FP.

1.9.2. Curva ROC y AUC-ROC

La curva ROC grafica:

$$\text{TPR} = \frac{TP}{TP + FN} \quad \text{vs} \quad \text{FPR} = \frac{FP}{FP + TN}$$

para todos los umbrales posibles.

El **AUC-ROC** (área bajo la curva ROC) resume la capacidad discriminante:

- 0,5: similar al azar,
- 1,0: discriminación perfecta.

Interpretación probabilística útil. AUC-ROC puede interpretarse como la probabilidad de que el modelo asigne mayor score a un impago aleatorio que a un no-impago aleatorio.

1.9.3. Curva Precision-Recall y PR-AUC

En contextos desbalanceados, la curva Precision-Recall suele ser más informativa. Grafica **precisión** vs **recall** al variar el umbral.

El **PR-AUC** enfatiza el desempeño sobre la clase positiva (impago), por lo que es especialmente relevante cuando $Y = 1$ es raro.

Comentario práctico. Dos modelos con AUC-ROC similar pueden diferir notablemente en PR-AUC.

1.10. Evaluación probabilística y calibración

1.10.1. Qué significa calibración

Un modelo está bien calibrado si, por ejemplo, entre las observaciones a las que asigna $\hat{p} \approx 0{,}20$, aproximadamente el 20 % realmente impaga.

Formalmente, de manera ideal:

$$\mathbb{P}(Y = 1 \mid \hat{p} = q) = q.$$

Por qué importa en riesgo de crédito La calibración es crucial si se usan probabilidades para:

- estimar pérdidas esperadas,
- asignar límites o tasas,
- segmentar portafolio por riesgo,
- tomar decisiones de negocio con base en riesgo absoluto.

1.10.2. Brier score

El **Brier score** mide error cuadrático de probabilidades:

$$\mathrm{BS} = \frac{1}{n} \sum_{i=1}^{n} (\hat{p}_i - y_i)^2.$$

Sus propiedades:

- menor es mejor,
- penaliza probabilidades alejadas de la realidad,
- combina aspectos de discriminación y calibración.

Ejemplo básico Supongamos 4 observaciones:

$$(y_i) = (1, 0, 1, 0), \qquad (\hat{p}_i) = (0{,}9, 0{,}7, 0{,}4, 0{,}2).$$

Entonces:

$$\begin{aligned} \mathrm{BS} &= \frac{1}{4}\left[(0{,}9-1)^2 + (0{,}7-0)^2 + (0{,}4-1)^2 + (0{,}2-0)^2\right] \\ &= \frac{1}{4}(0{,}01 + 0{,}49 + 0{,}36 + 0{,}04) = \frac{0{,}90}{4} = 0{,}225. \end{aligned}$$

1.10.3. Curvas de calibración (reliability diagrams)

Se construyen agrupando observaciones por intervalos de probabilidad (bins), por ejemplo:

$$[0, 0{,}1), [0{,}1, 0{,}2), \ldots, [0{,}9, 1{,}0].$$

Para cada bin B_k se calcula:

- probabilidad media predicha: $\bar{p}_k$,
- frecuencia observada de impago: $\bar{y}_k$.

Se grafica $\bar{y}_k$ vs $\bar{p}_k$.

- Si los puntos caen sobre la diagonal $y = x$, hay buena calibración.
- Si están por encima de la diagonal, el modelo *subestima* el riesgo.
- Si están por debajo, el modelo *sobreestima* el riesgo.

Ejemplo conceptual. Si en el bin de predicción promedio $\bar{p}_k = 0{,}30$ la tasa observada es $\bar{y}_k = 0{,}45$, el modelo está subestimando riesgo en ese rango.

1.10.4. Calibración post-hoc

Algunos modelos (especialmente boosting y bosques) pueden discriminar bien pero estar mal calibrados. En esos casos, se puede recalibrar.

(a) Platt scaling Ajusta una regresión logística sobre los scores del modelo base:

$$\hat{p}_{\mathrm{cal}} = \sigma(as + b),$$

donde s es el score bruto del modelo y $\sigma(z) = 1/(1 + e^{-z})$.

(b) Regresión isotónica Ajusta una función monótona no paramétrica:

$$\hat{p}_{\mathrm{cal}} = g(s), \quad g \text{ no decreciente.}$$

Es más flexible, pero puede sobreajustar si hay pocos datos.

Regla práctica. La calibración post-hoc debe ajustarse usando **validación** (no test), y evaluarse en test para evitar optimismo.

1.11. Selección de umbral y costos de decisión

1.11.1. Umbral de clasificación

Aunque el modelo entregue $\hat{p}$, para ciertas acciones se requiere una etiqueta:

$$\hat{y} = \mathbf{1}\{\hat{p} \geq \tau\}.$$

El umbral $\tau = 0{,}5$ rara vez es óptimo en crédito.

1.11.2. Selección basada en costos

Sea:

- C_{FN}: costo de aprobar a quien impaga,
- C_{FP}: costo de rechazar a quien habría pagado.

Se puede elegir τ minimizando un costo esperado aproximado:

$$\text{Costo}(\tau) = C_{\text{FN}} \cdot FN(\tau) + C_{\text{FP}} \cdot FP(\tau).$$

Comentario. Este proyecto puede iniciar con comparación de métricas estándar, y dejar la optimización por costo como extensión natural.

1.12. Explicabilidad del modelo

1.12.1. Por qué explicabilidad

En riesgo de crédito, la explicabilidad es importante por:

- transparencia y confianza,
- auditoría y regulación,
- detección de errores o variables problemáticas,
- comunicación a usuarios técnicos y no técnicos.

1.12.2. Explicabilidad global vs local

- **Global**: cuáles variables son relevantes en promedio en el modelo.
- **Local**: por qué una observación específica recibió cierta PD.

1.12.3. Importancia de variables

En modelos de árboles se usa con frecuencia:

- importancia por reducción de impureza,
- importancia por permutación (más robusta conceptualmente).

Precaución. La importancia no implica causalidad. Una variable puede aparecer importante por correlación con otra o por sesgos de muestreo.

1.12.4. SHAP (introducción conceptual)

SHAP (*SHapley Additive exPlanations*) asigna a cada variable una contribución a la predicción de una observación, inspirado en valores de Shapley de teoría de juegos.

De manera simplificada, para una predicción $f(x)$:

$$f(x) \approx \phi_0 + \sum_{j=1}^{p} \phi_j,$$

donde:

- ϕ_0 es una predicción base (promedio),
- ϕ_j es la contribución de la variable j a mover la predicción hacia arriba o abajo.

Interpretación local. Si para un cliente se obtiene:

$$\phi_{\text{historial_mora}} > 0, \qquad \phi_{\text{ingreso}} < 0,$$

esto sugiere que el historial de mora elevó el riesgo estimado, mientras que el ingreso lo redujo (respecto al valor base).

Valor práctico. SHAP ayuda a:

- explicar casos individuales,
- detectar comportamientos no esperados,
- comparar patrones por segmentos.

1.13. Sesgo y evaluación por subgrupos (fairness operativa básica)

Aun si un modelo tiene buen desempeño global, puede comportarse de forma desigual por segmentos (plazo, región, tipo de crédito, etc.). Por ello es recomendable evaluar:

- métricas de discriminación por subgrupo (AUC, PR-AUC),
- calibración por subgrupo (curvas o Brier),
- tasas de error por subgrupo a un umbral dado.

Ejemplo conceptual. Un modelo puede estar bien calibrado en la cartera general, pero subestimar sistemáticamente el riesgo en préstamos de plazo largo. Esto tendría implicaciones relevantes de negocio.

Alcance del proyecto. No necesariamente se abordará una teoría completa de *fairness*, pero sí una **revisión de robustez por subgrupos** como buena práctica.

1.14. Reproducibilidad y calidad del pipeline (base teórica-práctica)

Aunque suele verse como parte metodológica, en ciencia de datos aplicada la reproducibilidad también tiene fundamento conceptual: un resultado científico/técnico debe poder regenerarse.

1.14.1. Elementos clave

- **Control de versiones** (git),
- **Entorno reproducible** (conda/poetry y versiones fijas),
- **Semillas aleatorias** documentadas,
- **Data dictionary** (definiciones de variables, rangos, tipos),
- **Pipelines** deterministas cuando sea posible,
- **Logs y metadatos** (fecha de descarga, versión de dataset, configuración),
- **Pruebas mínimas** para funciones clave.

Relevancia en riesgo de crédito. Esto permite:

- auditoría,
- trazabilidad,
- repetición de experimentos,
- comparabilidad entre versiones del modelo.

1.15. Ejemplos básicos integradores

1.15.1. Ejemplo 1: tasa de impago por segmento

Supongamos el siguiente segmento de préstamos de 36 meses:

$$\#S = 200, \qquad \#\{i \in S : Y_i = 1\} = 18.$$

Entonces:

$$\widehat{r}(S) = \frac{18}{200} = 0{,}09.$$

La tasa de impago observada del segmento es 9 %.

Si el modelo asigna a ese segmento una PD media de:

$$\frac{1}{200}\sum_{i\in S}\hat{p}_i = 0{,}06,$$

entonces el modelo parece *subestimar* el riesgo de ese segmento (al menos descriptivamente).

1.15.2. Ejemplo 2: logística con una variable

Supongamos un modelo con una sola variable x = razón deuda/ingreso:

$$\text{logit}(p) = -2 + 3x.$$

Para $x = 0{,}2$:

$$\text{logit}(p) = -2 + 3(0{,}2) = -1{,}4 \quad \Rightarrow \quad p = \frac{1}{1+e^{1{,}4}} \approx 0{,}198.$$

Para $x = 0{,}6$:

$$\text{logit}(p) = -2 + 3(0{,}6) = -0{,}2 \quad \Rightarrow \quad p = \frac{1}{1+e^{0{,}2}} \approx 0{,}450.$$

La PD aumenta al aumentar la razón deuda/ingreso, como se esperaría en este ejemplo.

1.15.3. Ejemplo 3: efecto del umbral

Supongamos 5 clientes con probabilidades estimadas:

$$(0{,}82, 0{,}61, 0{,}40, 0{,}22, 0{,}10).$$

- Con $\tau = 0{,}5$, se clasifican como impago los dos primeros.
- Con $\tau = 0{,}3$, se clasifican como impago los tres primeros.

Al bajar el umbral suele aumentar el recall y disminuir la precisión.

1.15.4. Ejemplo 4: calibración por bins

Supongamos un bin con 100 préstamos y probabilidad media predicha 0,15. Si observamos 23 impagos:

$$\bar{p} = 0{,}15, \qquad \bar{y} = 0{,}23.$$

El modelo subestima riesgo en ese rango.

1.16. Relación entre conceptos

Es útil que el estudiante distinga las siguientes preguntas:

1. **¿Qué queremos predecir?**
   Evento de impago $Y = 1$ en un horizonte definido.

2. **¿Qué produce el modelo?**
   Probabilidad estimada $\hat{p} = \widehat{\mathrm{PD}}(x)$.

3. **¿Cómo evaluamos si "ordena" bien?**
   AUC-ROC y PR-AUC (discriminación).

4. **¿Cómo evaluamos si las probabilidades son confiables?**
   Brier score y curvas de calibración.

5. **¿Qué hacemos si la clase positiva es rara?**
   Tratamiento de desbalance (weights, submuestreo, SMOTE) y métricas adecuadas.

6. **¿Cómo explicamos el modelo?**
   Coeficientes (logística), importancias y SHAP (árboles/boosting).

7. **¿Cómo evitamos errores metodológicos?**
   Partición correcta, evitar leakage, pipeline reproducible.

1.17. Errores comunes que debemos evitar

- Reportar sólo *accuracy* en datasets desbalanceados.
- Comparar modelos con diferentes particiones (comparación injusta).
- Aplicar SMOTE antes de dividir train/test (leakage).
- Ajustar calibración usando el conjunto test.
- Interpretar importancia de variables como causalidad.
- Evaluar sólo desempeño global y no por subgrupos.
- No documentar definición exacta del target de impago.

1.18. Resumen conceptual del marco teórico

El proyecto se sustenta en la combinación de tres pilares:

1. **Modelado estadístico y ML para clasificación binaria** (PD),
2. **Evaluación probabilística y calibración** (probabilidades útiles y coherentes),
3. **Explicabilidad y robustez** (interpretación, subgrupos, reproducibilidad).

La regresión logística proporciona una base interpretable y auditable, mientras que modelos basados en árboles pueden mejorar el poder predictivo al capturar no linealidades e interacciones. No obstante, su uso exige especial cuidado en calibración, desbalance y explicabilidad.

En conjunto, este marco teórico permite al estudiante comprender no sólo *cómo entrenar* modelos de riesgo de crédito, sino también *cómo evaluarlos, interpretarlos y validarlos* de manera técnicamente sólida y útil para aplicaciones reales.

1.19. Apéndice breve de notación

Símbolo	Significado
$Y \in \{0, 1\}$	Variable objetivo (impago / no impago)
X	Vector de características
$\mathrm{PD}(x)$	Probabilidad de impago condicional
$\hat{p}_i$	Probabilidad estimada para observación i
τ	Umbral de clasificación
TP, FP, TN, FN	Componentes de la matriz de confusión
AUC-ROC	Área bajo curva ROC (discriminación)
PR-AUC	Área bajo curva Precision-Recall
BS	Brier score (error probabilístico)
SHAP	Explicaciones aditivas basadas en Shapley